
Analyse de la peau

Année universitaire 2025-2026




ASMA SELLAMI



OUMAIMA HOUIMEL



SALEM AJIMI



AYMEN ABIDI



MAYSSEN JEMMALI


Plan

- 1 *Introduction & Problématique*
- 2 *Compréhension du métier*
- 3 *Compréhension et Préparation des Données*
- 4 *Stratégie de Modélisation*
- 5 *Évaluation des Performances*
- 6 *Benchmarking des Modèles*

Introduction

La peau est un écosystème complexe **influencé** par la **biologie** (âge, hydratation) et **l'environnement** (température, humidité).

L'objectif Principal est de **prédire** avec précision le **type** de peau d'un individu.








Compréhension du métier


Objectifs Métier (BO)	Objectifs Data Science (DSO)	Datasets / Variables Associées
Diagnostic personnalisé Identifier le type de peau de l'utilisateur.	Classification multiclasse Entraînement sur la cible <code>Skin_Type</code>	Variables prédictives : <code>Oil_Level</code> , <code>Humidity</code>
Fiabilité des recommandations Garantir le meilleur algorithme possible.	Optimisation & Benchmarking Comparaison (XGBoost, SVM, RF...).	Données préparées : Train set (scaled) et Test set.

Compréhension des données


Categorical Feature Distributions — Full 10K



Skin Type — Class Proportions




Correlation Matrix — Numeric Features




Corrélation des Variables Numériques

- Forte relation négative (-0.81) entre le `Skin_Score` et le `Skin_Age`
- une peau en **mauvaise** santé **vieillit** beaucoup plus **vite**.

Analyse des Distributions: Impact Environnemental et Physiologique



Distribution du Skin Type par Catégorie



Préparation des données




- **Encodage Ordinal** : Transformation des niveaux (Hydration , Oil , Sensitivity) en échelle numérique (0 = Low, 1 = Medium, 2 = High).
- **Encodage Nominal** : Label Encoding pour Gender et la cible Skin_Type

```
# — Normalisation (StandardScaler) —  
scaler = StandardScaler()  
X_train_scaled = scaler.fit_transform(X_train)  
X_test_scaled = scaler.transform(X_test)  
  
print("Données normalisées – Moyenne train (doit ≈ 0) :", X_train_scaled.mean(axis=0).round(3))  
print("Écart-type train (doit ≈ 1) :", X_train_scaled.std(axis=0).round(3))
```


```
Données normalisées – Moyenne train (doit ≈ 0) : [-0. -0. -0.  0. -0. -0. -0.]  
Écart-type train (doit ≈ 1) : [1. 1. 1. 1. 1. 1. 1.]
```

Choix des modèles de classification


K-Nearest Neighbors (KNN)




Support Vector Machine (SVM)




Decision Tree



Random Forest (Bagging)



XGBoost (Boosting)




Justification & Complexité

Modèle	PROS 	CONS 
KNN	Simple, baseline	Coût élevé en prédiction
SVM	Bonne séparation non linéaire	Complexité élevée ($\approx O(N^3)$)
Decision Tree	Interprétable	Risque d'overfitting
Random Forest	Réduction de l'overfitting	Moins interprétable
XGBoost	Très performant Optimisé et rapide	Risque d'overfitting s'il est mal réglé

Évaluation des performances


Choix des métriques



Accuracy

Precision

Recall



F1-score


Visualisation des performances des modèles :

KNN

	precision	recall	f1-score
Combination	0.38	0.11	0.17
Dry	0.88	0.96	0.92
Normal	0.73	0.87	0.79
Oily	0.79	0.86	0.82
accuracy			0.78
macro avg	0.70	0.70	0.68
weighted avg	0.73	0.78	0.74

CV accuracy : 0.7880

Test accuracy: 0.7760 (77.60%)




SVM

=== Rapport OvR ===

	precision	recall	f1-score
Combination	0.60	0.16	0.25
Dry	0.90	0.97	0.93
Normal	0.74	0.89	0.81
Oily	0.80	0.87	0.83
accuracy			0.80
macro avg	0.76	0.72	0.71
weighted avg	0.78	0.80	0.76


Entraînement One-vs-Rest (OvR)...

Temps OvR : 4.78s | Accuracy OvR : 0.7950



XGBOOST

	precision	recall	f1-score
Combination	0.48	0.24	0.32
Dry	0.92	0.95	0.93
Normal	0.76	0.86	0.81
Oily	0.79	0.85	0.82
accuracy			0.79
macro avg	0.74	0.73	0.72
weighted avg	0.77	0.79	0.77
Best CV score : 0.8001			
Test Accuracy : 0.7930 (79.30%)			





Interprétation des résultats

- Les classes **Dry**, **Normal** et **Oily** sont globalement **bien** reconnues par tous les modèles, avec des performances **élevées** en précision et en rappel.
- La classe **Combination** est la plus **difficile** à classer en raison de son **chevauchement** avec les autres types de peau, rendant la frontière de décision **moins claire**.




Benchmarking des modèles




Benchmarking des Algorithmes — Métriques de Classification sur le Jeu de Test



Accuracy sur le Jeu de Test





F1-Score Weighted (pondéré)




F1-Score par Classe — Analyse Détaillée par Algorithme



Courbes ROC — Comparaison de tous les Algorithmes (One-vs-Rest)




Classement Final des Algorithmes — Score Composite Multi-Critères



Rang	Algorithme	Accuracy	F1 Macro	AUC	Recommandation
	Random Forest	~81%	~0.73	~0.91	✅ Déploiement principal
	XGBoost	~79%	~0.72	0.913	✅ Modèle de secours
	SVM (RBF)	~79%	~0.71	~0.88	⚠️ Coût computationnel élevé
	Decision Tree	~79%	~0.72	~0.87	📖 Bon pour l'interprétabilité
	KNN	~78%	~0.68	~0.882	❌ Inférence lente

Forces et faiblesses des approches

- Les **méthodes d'ensemble** comme **Random Forest** et **XGBoost** offrent de **meilleures** performances et robustesse, au prix d'une **complexité** plus **élevée** et d'une **moindre** interprétabilité.
- Les modèles **simples** comme **KNN** et **l'arbre de décision** sont **faciles à interpréter** mais **moins** performants sur des relations **complexes**.





Merci pour votre attention

